

# Fouilles de données et Medias sociaux

Master 2 DAC - FDMS

Sylvain Lamprier

UPMC

## Décision sur les réseaux


- Décision sur les réseaux
  - Très large volume de données
  - Contexte dynamique
  - Contraintes temps réel
  - Parfois peu d'informations sur chaque entité du réseau
- Exemples de tâches
  - Publicité en ligne
  - Recommandation personnalisée de produits
  - Crawling / Collecte de données
  - Maximisation d'audimat
  - ...
- Modèles traditionnels parfois peu adaptés
  - Apprentissage coûteux
  - Besoin de grandes quantités d'informations pour être performants
  - Peu flexibles aux évolutions sur le réseau
  - Pas de notion de "vitesse d'apprentissage"

⇒ Modèles pour la prise de décision temps réel sur les réseaux

# Problèmes de bandits


- Prise de décision sur les réseaux
  - Apprentissage en continu
  - Décision Temps réel
  - Pas ou peu d'informations sur les entités manipulées

⇒ Problèmes de bandits-manchots multi-bras

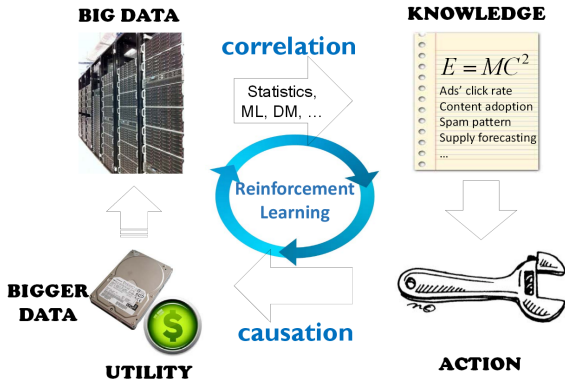


# Apprentissage par renforcement


- Apprentissage supervisé
  - On dispose d'une vérité terrain permettant de juger chaque décision
  - ⇒ Minimiser les erreurs par rapport à cette vérité terrain
- Apprentissage par renforcement
  - Processus de decision markovien (MDP)
  - Apprentissage faiblement supervisé : on ne dispose que d'indicateurs de l'utilité des décisions prises
  - ⇒ Maximiser le reward cumulé



# Apprentissage par renforcement



# Apprentissage par renforcement



- Problèmes de bandits = Problèmes d'apprentissage par renforcement
  - Reward immédiat
  - Etat courant ne dépend pas des actions passées
- Stochastique vs Adverse
- Stationnaire vs Non-stationnaire
- Bras inter-dépendents ou indépendents
- Prise en compte du contexte décisionnel ?



- Problèmes de bandits = Problèmes d'apprentissage par renforcement
  - Reward immédiat
  - Etat courant ne dépend pas des actions passées
- **Stochastique** vs Adverse
- **Stationnaire** vs Non-stationnaire
- Bras inter-dépendents ou **indépendents**
- Prise en compte du contexte décisionnel ?

- Problèmes de bandits multi-bras

- $K$  actions (bras) possibles à chaque pas de temps  $t$ , une seule effectuée :  $I_t$
- Resultat de l'action  $i$  au temps  $t$  :  $\omega_{i,t} \in \Omega$   
*Seul le resultat du bras joué au temps  $t$  est observé:  $\omega_{I_t,t}$*
- Fonction de reward  $g : \Omega \rightarrow [0; 1]$  définie pour estimer l'utilité du resultat d'une action
- Hypothèse (cas stochastique): les rewards obtenus pour chaque action sont i.i.d. et suivent une distribution inconnue  $\nu_i$  d'espérance  $\mu_i$
- Une stratégie de décision (ou politique)  $\pi$  détermine, en fonction des actions passées  $I_1 \dots I_{t-1}$ , l'action  $I_t = \pi_t$  à effectuer à l'instant  $t$
- Objectif: Maximiser le reward cumulé sur la période d'actions  $1..T$ :

$$\pi^* = \arg \max_{\pi} \sum_{t=1}^T g(\omega_{\pi_t,t})$$

- Notion centrale de regret :
  - Regret  $\rho_n$  d'avoir effectué les actions  $\pi_1.. \pi_n$  dans les  $n$  premiers pas de temps plutôt que l'action  $i^* = \arg \max_i \mu_i$  de meilleure espérance:

$$\rho_n = \sum_{t=1}^n g(\omega_{i^*,t}) - \sum_{t=1}^n g(\omega_{\pi_t,t})$$

- Espérance de Regret  $\mathbb{E}(\rho_n)$  :

$$\mathbb{E}(\rho_n) = n \times \mu_{i^*}^* - \mathbb{E}\left(\sum_{t=1}^n \mu_{\pi_t}\right)$$

- Espérance empirique des rewards de  $i$  après  $x$  essais de  $i$ :

$$\hat{\mu}_{i,x} = \frac{1}{x} \sum_{s=1}^x g_{i,s}$$

Avec  $g_{i,s}$  le  $s$ -ième reward obtenu par le bras  $i$ .

- Plus on joue un bras, meilleure est l'estimation de son espérance de reward:

$$\lim_{x \rightarrow \infty} \hat{\mu}_{i,x} = \mu_i$$

- Proposition de politique  $\pi$ :
  - $\pi_t = \arg \max_{i \in K} \hat{\mu}_{i, T_i(t)}$   
avec  $T_i(t)$  le nombre de fois que  $i$  a été joué au temps  $t$

- Proposition de politique  $\pi$ :
  - $\pi_t = \arg \max_{i \in K} \hat{\mu}_{i, T_i(t)}$   
avec  $T_i(t)$  le nombre de fois que  $i$  a été joué au temps  $t$
  - Qu'en pensez-vous ?

- Proposition de politique  $\pi$ :

- $\pi_t = \arg \max_{i \in K} \hat{\mu}_{i, T_i(t)}$

avec  $T_i(t)$  le nombre de fois que  $i$  a été joué au temps  $t$

- Qu'en pensez-vous ?

⇒ Pas d'exploration

- Proposition de politique  $\pi$ :

- $\pi_t = \arg \max_{i \in K} \hat{\mu}_{i, T_i(t)}$

- avec  $T_i(t)$  le nombre de fois que  $i$  a été joué au temps  $t$

- Qu'en pensez-vous ?

⇒ Pas d'exploration

⇒ Risque de rester "bloqué" sur un bras sous-optimal



- Proposition de politique  $\pi$ :

- $\pi_t = \arg \max_{i \in K} \hat{\mu}_{i, T_i(t)}$

- avec  $T_i(t)$  le nombre de fois que  $i$  a été joué au temps  $t$

- Qu'en pensez-vous ?

⇒ Pas d'exploration

⇒ Risque de rester "bloqué" sur un bras sous-optimal

⇒ Définir un compromis entre:

- Exploitation:

- Récupération des gains fournis par le meilleur bras actuel

- Exploration:

- Découverte de nouveaux bras
    - Raffinement de l'estimation de bras  $\neq \arg \max_{i \in K} \hat{\mu}_{i, T_i(t)}$

## Théorème [Lai & Robbins, 1985]

Il est possible de définir des stratégies tel que:

$$\mathbb{E}(\rho_n) \leq cK \ln(n)$$

Avec  $c \approx \frac{1}{\Delta^*}$ , où  $\Delta^* = \mu^* - \max_{j: \mu_j < \mu^*} \mu_j$

- Un premier algo : Epsilon-greedy
  - A chaque itération  $t$ :
    - Avec une probabilité de  $1 - \epsilon_t$ ,  $\pi_t = \arg \max_{i \in K} \hat{\mu}_{i, T_i(t)}$  (bras de meilleure espérance empirique)
    - Avec une probabilité de  $\epsilon_t$ ,  $\pi_t =$  bras choisi au hasard
  - Compromis exploitation-exploration défini par  $\epsilon_t$ 
    - Performances très dépendantes de  $\epsilon_t$
    - $\epsilon_t$  généralement décroissant en fonction de  $t$
- ⇒ De nombreuses variantes existent

- Un premier algo : Epsilon-greedy
- A chaque itération  $t$ :
  - Avec une probabilité de  $1 - \epsilon_t$ ,  $\pi_t = \arg \max_{i \in K} \hat{\mu}_{i, T_i(t)}$  (bras de meilleure espérance empirique)
  - Avec une probabilité de  $\epsilon_t$ ,  $\pi_t =$  bras choisi au hasard
- Compromis exploitation-exploration défini par  $\epsilon_t$ 
  - Performances très dépendantes de  $\epsilon_t$
  - $\epsilon_t$  généralement décroissant en fonction de  $t$

⇒ De nombreuses variantes existent
- Est-il possible de spécifier  $\epsilon_t$  de manière à garantir un regret logarithmique ?

## Tuned Epsilon-greedy

### Théorème [Auer et al., 2002]

Si  $\epsilon_t = \min\{1; \frac{12}{d^2 t}\}$  avec  $d \in ]0; \Delta^*]$ , alors le regret instantané au temps  $n$  de la stratégie epsilon-greedy est dans le pire des cas en  $O(\frac{K}{dn})$

## Tuned Epsilon-greedy

### Théorème [Auer et al., 2002]

Si  $\epsilon_t = \min\{1; \frac{12}{d^2 t}\}$  avec  $d \in ]0; \Delta^*]$ , alors le regret instantané au temps  $n$  de la stratégie epsilon-greedy est dans le pire des cas en  $O(\frac{K}{dn})$

⇒ Si on connaît  $\Delta^*$  alors il est possible de définir une stratégie epsilon-greedy où  $\mathbb{E}(\rho_n) \leq \frac{K}{\Delta^*} \ln(n) + C$  (avec  $C$  une constante)

## Tuned Epsilon-greedy

### Théorème [Auer et al., 2002]


Si  $\epsilon_t = \min\{1; \frac{12}{d^2 t}\}$  avec  $d \in ]0; \Delta^*]$ , alors le regret instantané au temps  $n$  de la stratégie epsilon-greedy est dans le pire des cas en  $O(\frac{K}{dn})$

- ⇒ Si on connaît  $\Delta^*$  alors il est possible de définir une stratégie epsilon-greedy où  $\mathbb{E}(\rho_n) \leq \frac{K}{\Delta^*} \ln(n) + C$  (avec  $C$  une constante)
- Pb:  $\Delta^*$  n'est pas connu a priori ⇒ Définition d'un paramètre  $d$  efficace difficile

- Une stratégie centrale : UCB
  - Upper-Confidence Bound [Auer et al., 2002]

$$\pi_t = \arg \max_i B_{t, T_i(t-1)}(i), \text{ avec } B_{t,s}(i) = \hat{\mu}_{i,s} + \sqrt{\frac{2 \log t}{s}}$$

- Stratégie optimiste :
  - ⇒  $B_{t, T_i(t-1)}(i)$  représente une borne supérieure de  $\hat{\mu}_{i, T_i(t-1)}$  à l'iteration  $t$



- ⇒ On choisit le bras qui serait le meilleur si les valeurs des bras étaient les meilleures possibles selon l'intervale de confiance



- Stratégie optimiste :
  - Inégalités de Chernoff-Hoeffding pour des variables aléatoires indépendantes  $X_i \in [0, 1]$  d'espérance  $\mu$  :

$$P\left(\frac{1}{s} \sum_{i=1}^s X_i - \mu \geq \epsilon\right) \leq \exp^{-2s\epsilon^2} \quad \text{et} \quad P\left(\frac{1}{s} \sum_{i=1}^s X_i - \mu \leq -\epsilon\right) \leq \exp^{-2s\epsilon^2}$$

- On a alors pour tout bras  $i$  :

$$P\left(\hat{\mu}_{i, T_i(t-1)} + \sqrt{\frac{2 \log t}{T_i(t-1)}} \leq \mu_i\right) \leq t^{-4} \quad \text{et} \quad P\left(\hat{\mu}_{i, T_i(t-1)} - \sqrt{\frac{2 \log t}{T_i(t-1)}} \geq \mu_i\right) \leq t^{-4}$$

⇒ Cela définit un intervalle de confiance de niveau  $1 - t^{-4}$ :

$$\mu_i - \sqrt{\frac{2 \log t}{T_i(t-1)}} \stackrel{(a)}{\leq} \hat{\mu}_{i, T_i(t-1)} \stackrel{(b)}{\leq} \mu_i + \sqrt{\frac{2 \log t}{T_i(t-1)}}$$

- UCB choisit un bras sous-optimal  $i$ , i.e.  $B_{t,s}(i) \geq B_{t,s^*}(i^*)$ , si:

$$\hat{\mu}_{i, T_i(t-1)} + \sqrt{\frac{2 \log t}{T_i(t-1)}} \geq \hat{\mu}_{i^*, T_{i^*}(t-1)} + \sqrt{\frac{2 \log t}{T_{i^*}(t-1)}}$$

- Si on est dans l'intervale de confiance, on a alors dans ce cas :

$$\mu_i + 2\sqrt{\frac{2 \log t}{T_i(t-1)}} \geq \mu^*, \text{ soit: } T_i(t-1) \leq \frac{8 \log t}{\Delta_i^2}$$

- Sinon, c'est que l'une des inégalités (a) ou (b) n'est pas vérifiée

- On pose, pour tout entier  $u \geq 0$  :

$$T_i(n) \leq u + \sum_{t=u+1}^n \mathbb{I}(\exists s : u < s \leq t, \exists s^* : 1 \leq s^* \leq t, B_{t,s}(i) \geq B_{t,s^*}(i^*))$$

- En choisissant  $u = \frac{8 \log n}{\Delta_i^2}$ , on sait alors qu'un bras sous-optimal est choisi seulement si (a) ou (b) n'est pas vérifiée. Or:
  - (a) n'est pas vérifiée avec une proba de  $t^{-4}$
  - (b) n'est pas vérifiée avec une proba de  $t^{-4}$

- Donc :

$$\begin{aligned} \mathbb{E} T_i(n) &\leq \frac{8 \log n}{\Delta_i^2} + \sum_{t=u+1}^n \left[ \sum_{s=u+1}^t t^{-4} + \sum_{s=1}^t t^{-4} \right] \\ &\leq \frac{8 \log n}{\Delta_i^2} + 1 + \frac{\pi^2}{3} \end{aligned}$$

- On pose, pour tout entier  $u \geq 0$  :

$$T_i(n) \leq u + \sum_{t=u+1}^n \mathbb{I}(\exists s : u < s \leq t, \exists s^* : 1 \leq s^* \leq t, B_{t,s}(i) \geq B_{t,s^*}(i^*))$$

- En choisissant  $u = \frac{8 \log n}{\Delta_i^2}$ , on sait alors qu'un bras sous-optimal est choisi seulement si (a) ou (b) n'est pas vérifiée. Or:
  - (a) n'est pas vérifiée avec une proba de  $t^{-4}$
  - (b) n'est pas vérifiée avec une proba de  $t^{-4}$

- Donc :

$$\begin{aligned} \mathbb{E} T_i(n) &\leq \frac{8 \log n}{\Delta_i^2} + \sum_{t=u+1}^n \left[ \sum_{s=u+1}^t t^{-4} + \sum_{s=1}^t t^{-4} \right] \\ &\leq \frac{8 \log n}{\Delta_i^2} + 1 + \frac{\pi^2}{3} \end{aligned}$$

⇒ Borne supérieure logarithmique sur l'espérance du nombre de tirages de chaque bras sous-optimal

- Borne du regret à partir de cette borne du nombre de tirages des bras sous-optimaux ?

- Borne du regret à partir de cette borne du nombre de tirages des bras sous-optimaux ?

$$\mathbb{E}(\rho_n)$$

$$= n \times \mu_j^* - \mathbb{E}\left(\sum_{t=1}^n \mu_{\pi_t}\right)$$

- Borne du regret à partir de cette borne du nombre de tirages des bras sous-optimaux ?

$$\mathbb{E}(\rho_n)$$

$$= n \times \mu_j^* - \mathbb{E}\left(\sum_{t=1}^n \mu_{\pi_t}\right)$$

$$= n \times \mu_j^* - \sum_{i=1}^K \mathbb{E}_{T_i}(n) \times \mu_i$$

- Borne du regret à partir de cette borne du nombre de tirages des bras sous-optimaux ?

$$\mathbb{E}(\rho_n)$$

$$= n \times \mu_j^* - \mathbb{E}\left(\sum_{t=1}^n \mu_{\pi_t}\right)$$

$$= n \times \mu_j^* - \sum_{i=1}^K \mathbb{E}_{T_i}(n) \times \mu_i$$

$$= \sum_{i=1}^K \mathbb{E}_{T_i}(n) \times (\mu_j^* - \mu_i)$$



- Borne du regret à partir de cette borne du nombre de tirages des bras sous-optimaux ?

$$\mathbb{E}(\rho_n)$$

$$\begin{aligned} &= n \times \mu_j^* - \mathbb{E}\left(\sum_{t=1}^n \mu_{\pi_t}\right) \\ &= n \times \mu_j^* - \sum_{i=1}^K \mathbb{E}_{T_i}(n) \times \mu_i \\ &= \sum_{i=1}^K \mathbb{E}_{T_i}(n) \times (\mu_j^* - \mu_i) \\ &= \sum_{i=1}^K \mathbb{E}_{T_i}(n) \times \Delta_i \end{aligned}$$

- Borne du regret à partir de cette borne du nombre de tirages des bras sous-optimaux ?

$$\mathbb{E}(\rho_n)$$

$$\begin{aligned} &= n \times \mu_j^* - \mathbb{E}\left(\sum_{t=1}^n \mu_{\pi_t}\right) \\ &= n \times \mu_j^* - \sum_{i=1}^K \mathbb{E}_{T_i}(n) \times \mu_i \\ &= \sum_{i=1}^K \mathbb{E}_{T_i}(n) \times (\mu_j^* - \mu_i) \\ &= \sum_{i=1}^K \mathbb{E}_{T_i}(n) \times \Delta_i \\ &\leq \sum_{i \in \{1..K\} : \mu_i < \mu_j^*} \frac{8 \log n}{\Delta_i} + \Delta_j \left(1 + \frac{\pi^2}{3}\right) \end{aligned}$$

- Borne du regret à partir de cette borne du nombre de tirages des bras sous-optimaux ?

$$\mathbb{E}(\rho_n)$$

$$\begin{aligned} &= n \times \mu_j^* - \mathbb{E}\left(\sum_{t=1}^n \mu_{\pi_t}\right) \\ &= n \times \mu_j^* - \sum_{i=1}^K \mathbb{E}_{T_i}(n) \times \mu_i \\ &= \sum_{i=1}^K \mathbb{E}_{T_i}(n) \times (\mu_j^* - \mu_i) \\ &= \sum_{i=1}^K \mathbb{E}_{T_i}(n) \times \Delta_i \\ &\leq \sum_{i \in \{1..K\} : \mu_i < \mu_{j^*}} \frac{8 \log n}{\Delta_i} + \Delta_{j^*} \left(1 + \frac{\pi^2}{3}\right) \\ &\leq K \frac{8 \log n}{\Delta^*} + K \Delta^* \left(1 + \frac{\pi^2}{3}\right) \end{aligned}$$

# UCB : Application à la publicité sur le Web

Exemple d'application d'UCB sur le Web : la publicité dans les moteurs de recherche [*Pandey&Olston, 2007*]

- Publicités  $A_1..A_k$
- Requêtes (ou mots)  $Q_1..Q_m$
- Revenu par clic  $a_{i,j}$  pour chaque paire publicité  $A_i$ -requête  $Q_j$
- Probabilité (inconnue)  $p_{i,j}$  que les utilisateurs cliquent sur la publicité  $A_i$  pour la requête  $Q_j$

⇒ Objectif: Maximiser les gains du moteur sur l'ensemble des  $n_j$  recherches selon chaque requête  $Q_j$  de la journée:


$$\sum_{i=1}^{n_j} \mathbb{I}(\text{clic sur la publicité } A_i \text{ affichée}) \times a_{i,j} \sim \sum_{i=1}^{n_j} p_{i,j} \times a_{i,j}$$

⇒ Choix de la publicité à afficher pour la  $i$ -ième recherche utilisant la requête  $Q_j$ :

$$A_i = \arg \max_{A_x \in A} (\hat{p}_{x,j}(i-1) + \sqrt{\frac{2 \log(i)}{n_{x,j}(i-1)}}) \times a_{x,j}$$

Avec sur les  $i-1$  premières recherches concernant la requête  $Q_j$ :

- $\hat{p}_{x,j}(i-1)$ : l'estimation de la probabilité de clic sur la pub  $A_x$
- $n_{x,j}(i-1)$ : le nombre de fois où  $A_x$  a été affiché



Collecte de données temps réel sur les réseaux sociaux  
[Gisselbrecht et al., 2015]

- Plateformes de streaming des réseaux
- Ecoute d'un nombre limité d'utilisateurs en simultané
- Pb: choisir les  $k$  utilisateurs avec le meilleur potentiel d'utilité selon la fonction de reward considérée:

$$\pi^* = \arg \max_{\pi} \sum_{t=1}^n \sum_{i \in \pi_t} g(\omega_{i,t})$$

⇒ UCBV appliqué à la sélection de  $k$  bras simultanés  
(Combinatorial UCBV)

# Problèmes de bandits: une variante d'UCB

- UCB-V [Audibert et al., 2007]

- Intuition

- Certains bras ont une variabilité des rewards plus importante que d'autres
    - Estimation des bras à plus grande variabilité plus difficile
  - ⇒ Meilleure prise en compte de ces bras par considération de la variance empirique des rewards

- Variance Empirique :

$$\hat{\sigma}_{i,x}^2 = \frac{1}{x} \sum_{s=1}^x (g_{i,s} - \hat{\mu}_{i,x})^2$$

- UCB-V = UCB avec borne supérieure de l'intervalle de confiance de la variance

$$\pi_t = \arg \max_i B_{t, T_i(t-1)}(i)$$

Avec

$$B_{t,s}(i) = \hat{\mu}_{i,s} + \sqrt{\frac{2 \log(t) \hat{\sigma}_{i,s}^2}{s}} + \frac{\log(t)}{2s}$$

# Problèmes de bandits: contexte de décision

- Contexte de décision
  - Contexte global variant à chaque itération
  - Contexte individuel (sur chaque bras) fixe (= profils des bras)
  - Contexte individuel variant à chaque itération
- Prise en compte du contexte
  - Contexte fixe (prise en compte globale)
    - ⇒ Accélérer la sélection des meilleurs bras en apprenant des "zones" de l'espace de représentation pertinentes
    - ⇒ Cold-start pour nouveaux bras entrant dans le pool
  - Contexte variable : Hypothèse de non-stationnarité des rewards
    - ⇒ Prise en compte globale de contextes individuels : rewards des bras suivent une distribution commune définie sur leurs contextes individuels
    - ⇒ Prise en compte individuelle d'un contexte global : chaque bras suit une distribution indépendante conditionnellement au contexte global de la décision
    - ⇒ Prise en compte individuelle d'un contexte individuel : rewards de chaque bras dépendent de son état actuel

- Lin-UCB [*Li et al., 2010*]

- UCB avec prise en compte individuelle du contexte
- Contexte de décision pour un bras  $i$  à l'instant  $t$  :  $x_{i,t}$
- Recherche pour chaque bras des corrélations entre contextes de décision et rewards obtenus :

$$\mathbb{E}_i(g(\omega_{i,t})|x_{i,t}) = \langle x_{i,t}, \theta_i^* \rangle$$

- Mise à jour des paramètres par Ridge Regression au fur et à mesure du processus

$$\hat{\theta}_i = \arg \min_{\theta_i} \|D_i \theta_i - c_i\|^2 + \|\theta_i\|^2$$

Avec  $D_i$  la matrice des contextes observés pour le bras  $i$  et  $c_i$  le vecteur des rewards obtenus correspondants

$$\Rightarrow \hat{\theta}_i = (D_i^T D_i + I)^{-1} D_i^T c_i$$



- Lin-UCB [Li et al., 2010]


- Il peut être montré qu'avec une probabilité  $1 - \delta$ :

$$| \langle x_{i,t}, \hat{\theta}_i \rangle - \mathbb{E}_i(g(\omega_{i,t}) | x_{i,t}) | \leq \alpha \sqrt{x_{i,t}^T (D_i^T D_i + I)^{-1} x_{i,t}}$$

Avec  $\alpha = 1 + \sqrt{\log(2/\delta)/2}$

- On a donc une borne supérieure de l'intervale de confiance pour  $\langle x_{i,t}, \hat{\theta}_i \rangle$ , qu'on peut donc utiliser à la manière d'UCB pour définir la politique  $\pi$ :

$$\pi_t = \arg \max_i \langle x_{i,t}, \hat{\theta}_i \rangle + \alpha \sqrt{x_{i,t}^T (D_i^T D_i + I)^{-1} x_{i,t}}$$



---

**Algorithm 1** LinUCB with disjoint linear models.

---

```
0: Inputs:  $\alpha \in \mathbb{R}_+$ 
1: for  $t = 1, 2, 3, \dots, T$  do
2:   Observe features of all arms  $a \in \mathcal{A}_t$ :  $\mathbf{x}_{t,a} \in \mathbb{R}^d$ 
3:   for all  $a \in \mathcal{A}_t$  do
4:     if  $a$  is new then
5:        $\mathbf{A}_a \leftarrow \mathbf{I}_d$  ( $d$ -dimensional identity matrix)
6:        $\mathbf{b}_a \leftarrow \mathbf{0}_{d \times 1}$  ( $d$ -dimensional zero vector)
7:     end if
8:      $\hat{\boldsymbol{\theta}}_a \leftarrow \mathbf{A}_a^{-1} \mathbf{b}_a$ 
9:      $p_{t,a} \leftarrow \hat{\boldsymbol{\theta}}_a^\top \mathbf{x}_{t,a} + \alpha \sqrt{\mathbf{x}_{t,a}^\top \mathbf{A}_a^{-1} \mathbf{x}_{t,a}}$ 
10:   end for
11:   Choose arm  $a_t = \arg \max_{a \in \mathcal{A}_t} p_{t,a}$  with ties broken arbitrarily, and observe a real-valued payoff  $r_t$ 
12:    $\mathbf{A}_{a_t} \leftarrow \mathbf{A}_{a_t} + \mathbf{x}_{t,a_t} \mathbf{x}_{t,a_t}^\top$ 
13:    $\mathbf{b}_{a_t} \leftarrow \mathbf{b}_{a_t} + r_t \mathbf{x}_{t,a_t}$ 
14: end for
```

---

$$\text{Avec } A_i = D_i^T D_i + I \text{ et } b_i = D_i^T c_i$$

## Application à la recommandation de news personnalisée [Li et al., 2010]

[www.yahoo.com](http://www.yahoo.com)



$A_t$  : available articles at time  $t$   
 $\mathbf{x}_t$  : user features (age, gender, interests, ...)  
 $a_t$  : the displayed article at time  $t$   
 $r_{t,a_t}$  : 1 for click, 0 for no - click

Average reward is click-through rate (CTR)

- Alternative aux stratégies optimistes : Thompson Sampling [*Thompson, 1933*], [*Kaufmann et al., 2012*]
- Maximisation de l'espérance de reward :

$$\pi_t = \arg \max_i \int \mathbb{I}[\mathbb{E}(r_t|i, x_{i,t}, \theta) = \max_{i'} \mathbb{E}(r_t|i', x_{i',t}, \theta)] P(\theta|\mathcal{D}) d\theta$$

Avec:

- $r_t = g(\omega_{i,\pi_t})$  le reward obtenu au temps  $t$
- $\mathcal{D} = \{(i, t, x_{i,t}, r_t)\}$  l'ensemble des observations passées;
- $P(r_t|\theta, i, t, x_{i,t})$  la vraisemblance des rewards en fonctions des observations
- $P(\theta|\mathcal{D}) \propto P(\mathcal{D}|\theta)P(\theta)$  la probabilité postérieure des paramètres conditionnnellement aux paramètres
- $P(\mathcal{D}|\theta)$  la vraisemblance des observations selon les paramètres
- $P(\theta)$  un prior sur l'ensemble de paramètres  $\theta$ ;

- Thompson Sampling en pratique
- A chaque iteration  $t$ :
  - 1 Échantillonnage des paramètres  $\theta^* \sim P(\theta|\mathcal{D})$
  - 2 Choix du bras qui maximise l'espérance du reward en fonction des paramètres et du contexte:

$$\pi_t = \arg \max_i \mathbb{E}(r|i, x_{i,t}, \theta^*)$$

- Thompson Sampling en pratique
  - Cas linéaire [Agrawal & Goyal, 2013]:
    - $\mathbb{E}(r_t|i, x_{i,t}, \theta) = \langle \theta, x_{i,t} \rangle$
    - On suppose que la vraisemblance  $P(\theta|\mathcal{D})$  suit une loi normale:  $\mathcal{N}(\hat{\theta}(t), v^2 B^{-1}(t))$
    - Avec :
      - $B(t) = I + \sum_{s=1}^{t-1} x_{\pi_i,s} x_{\pi_i,s}^T$
      - $\hat{\theta}(t) = B^{-1}(t) \sum_{s=1}^{t-1} r_s x_{\pi_i,s}$
      - $v$  une constante  $\approx 0.25$
- ⇒ Revient à supposer une distribution normale  $\mathcal{N}(\langle \theta, x_{i,t} \rangle, v^2)$  pour les rewards  $P(r_t|x_{\pi_i,t})$

- Thompson Sampling : Application a la selection de messages à publier
  - ⇒ Maximiser le nombre de *retweets* [Lage et al., 2013]
- A chaque ieration  $t$ :
  - 1 Recuperation de la liste des articles candidats au temps  $t$
  - 2 Publication de l'article avec le plus fort potentiel selon ses caractéristiques et les paramètres du modèle
  - 3 Observation de l'impact de la publication pendant une periode de temps donnée
  - 4 Mise à jour du modèle selon le nombre de *retweets* observés
- Caractéristiques considérées :
  - Contenu: tf normalisé des termes
  - Nombre d'Hashtags
  - Nombre de destinataires
  - Taille du message

# References

- [Agrawal & Goyal, 2013] S. Agrawal and N. Goyal. Thompson sampling for contextual bandits with linear payoffs. In ICML (3), pages 127–135, 2013
- [Audibert et al., 2007] J.-Y. Audibert, R. Munos, and C. Szepesvari. Tuning bandit algorithms in stochastic environments. In ALT'07, pages 150–165. 2007.
- [Auer et al., 2002] Peter Auer, Nicolo Cesa-Bianchi, and Paul Fischer. 2002. Finite-time Analysis of the Multiarmed Bandit Problem. Mach. Learn. 47, 2-3 (May 2002), 235-256.
- [Gisselbrecht et al., 2015] Thibault Gisselbrecht, Ludovic Denoyer, Patrick Gallinari and Sylvain Lamprier. WhichStreams: A Dynamic Approach for Focused Data Capture from Large Social Media. ICWSM 2015: 130-139
- [Kaufmann et al., 2012] E.Kaufmann, N.Korda, and R.Munos. Thompson Sampling: an asymptotically optimal finite-time analysis. In ALT'12.
- [Lage et al., 2013] Ricardo Lage, Ludovic Denoyer, Patrick Gallinari et al. (2013) Choosing which message to publish on social networks : A Contextual bandit approach. In IEEE/ACM International Conference on Advances in Social Networks Analysis and Mining.
- [Lai & Robbins, 1985] Lai, T. and Robbins, H. (1985). Asymptotically efficient adaptive allocation rules. Advances in Applied Mathematics ,6,4–22.
- [Li et al., 2010] Lihong Li, Wei Chu, John Langford, and Robert E. Schapire. 2010. A contextual-bandit approach to personalized news article recommendation. In Proceedings of the 19th international conference on World wide web (WWW '10). ACM, New York, NY, USA, 661-670.
- [Pandey & Olston, 2007] Sandeep Pandey and Christopher Olston. Handling advertisements of unknown quality in search advertising. Advances in Neural Information Processing Systems , 19:1065, 2007
- [Thompson, 1933] Thompson, William R. "On the likelihood that one unknown probability exceeds another in view of the evidence of two samples". Biometrika, 25(3-4):285–294, 1933.